Problem Set 2: Multiple hypothesis testing

E178: Economía Aplicada — Universidad de San Andrés
Fecha de entrega: 30 de agosto de 2024

Integrantes: Juan Batalla, Nina Di Costanzo Pereira, Catalina Gallardo e Ignacio Yenarópulos

En este problem set corregimos la inferencia de la Tabla 2 de Attanasio et al. (2020), que estudia con un experimento aleatorio en Colombia los efectos de un programa de visitas domiciliarias de estimulación psicosocial sobre las habilidades cognitivas y socioemocionales de los niños y sobre las inversiones de los padres (materiales y de tiempo).

1. Replicación de la Tabla 2

Para cada outcome estimamos por MCO una regresión de la medida en el seguimiento contra la variable de tratamiento, su valor de base (o el control de base indicado en el do-file provisto), el sexo del niño y efectos fijos de evaluador, con errores estándar clusterizados a nivel de municipio (96 clusters). La Tabla 1 presenta los resultados, con un panel por cada conjunto de outcomes, los outcomes en las columnas y el coeficiente de `treat` en las filas.

Tabla 1: Efectos del tratamiento (replicación de la Tabla 2 de Attanasio et al., 2020)

Panel A: habilidades cognitivas del niño

	(1) Cognitive	(2) Receptive lang.	(3) Expressive lang.	(4) Fine motor	(5) Words	(6) Phrases
Treatment	0.250***	0.174***	0.029	0.073	0.086	0.057
	(0.063)	(0.063)	(0.062)	(0.059)	(0.064)	(0.056)
Observaciones	1,263	1,263	1,262	1,261	1,321	1,321

Panel B: habilidades socioemocionales del niño

	(1) Difficult (-)	(2) Unsociable (-)	(3) Unstoppable (-)	(4) Inhibitory control	(5) Attentional focusing
Treatment	0.073	0.037	0.031	0.000	0.072
	(0.045)	(0.055)	(0.054)	(0.058)	(0.048)
Observaciones	1,325	1,325	1,325	1,322	1,322

Panel C: inversiones materiales

	(1) Play materials	(2) Coloring books	(3) Toys movement	(4) Toys shapes	(5) Shop-bought toys
Treatment	0.217***	-0.124**	-0.049	0.426***	0.020
	(0.064)	(0.056)	(0.065)	(0.088)	(0.061)
Observaciones	1,325	1,325	1,325	1,325	1,325

Panel D: inversiones de tiempo

	(1) Play activities	(2) Told a story	(3) Read to child	(4) Played with toys	(5) Named things
Treatment	0.280***	0.153**	0.403***	0.183***	0.144***
	(0.051)	(0.064)	(0.068)	(0.060)	(0.048)
Observaciones	1,325	1,325	1,325	1,325	1,325

Notas: Cada columna es una regresión distinta. Todas las medidas están estandarizadas; las marcadas con (-) están invertidas, de modo que un valor más alto indica mejor comportamiento. Panel A: Bayley (columnas 1–4) y MacArthur (5–6). Panel B: ICQ (1–3) y ECBQ (4–5). Paneles C y D: ítems del FCI. Controles: valor de base, sexo y efectos fijos de evaluador. Errores estándar clusterizados por municipio entre paréntesis. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

Nuestros resultados son muy parecidos a los del artículo (Tabla 2). Las diferencias en los coeficientes son pequeñas (la mayor es en *Read to child*: 0.403 contra 0.362), los errores estándar son prácticamente idénticos y los tamaños de muestra difieren en una observación. Las diferencias pueden deberse, como advierte la consigna, a que no contamos exactamente con las mismas variables que los autores. Sin corregir por múltiples hipótesis, el tratamiento tiene efectos positivos y significativos sobre el desarrollo cognitivo (Bayley cognitivo y lenguaje receptivo), sobre varias inversiones materiales (tipos de materiales de juego y juguetes para aprender formas, con un efecto negativo sobre los libros para colorear) y sobre las cinco medidas de inversión de tiempo. Ninguno de los ítems socioemocionales es significativo individualmente.

Tabla 2: Comparación con los resultados del artículo

	Artículo		Nuestra replicación	
Outcome	Coef.	EE	Coef.	EE
Panel A: habilidades cognitivas				
Bayley: Cognitive	0.250	(0.063)	0.250	(0.063)
Bayley: Receptive language	0.175	(0.063)	0.174	(0.063)
Bayley: Expressive language	0.032	(0.062)	0.029	(0.062)
Bayley: Fine motor	0.072	(0.060)	0.073	(0.059)
MacArthur: Words	0.092	(0.064)	0.086	(0.064)
MacArthur: Complex phrases	0.058	(0.055)	0.057	(0.056)
Panel B: habilidades socioemocionales				
ICQ: Difficult (-)	0.074	(0.045)	0.073	(0.045)
ICQ: Unsociable (-)	0.041	(0.054)	0.037	(0.055)
ICQ: Unstoppable (-)	0.032	(0.054)	0.031	(0.054)
ECBQ: Inhibitory control	−0.003	(0.058)	0.000	(0.058)
ECBQ: Attentional focusing	0.069	(0.049)	0.072	(0.048)
Panel C: inversiones materiales				
FCI: Types of play materials	0.215	(0.064)	0.217	(0.064)
FCI: Coloring and drawing books	−0.133	(0.056)	−0.124	(0.056)
FCI: Toys to learn movement	−0.048	(0.065)	−0.049	(0.065)
FCI: Toys to learn shapes	0.416	(0.088)	0.426	(0.088)
FCI: Shop-bought toys	0.024	(0.061)	0.020	(0.061)
Panel D: inversiones de tiempo				
FCI: Types of play activities	0.277	(0.050)	0.280	(0.051)
FCI: Told a story to child	0.138	(0.060)	0.153	(0.064)
FCI: Read to child	0.362	(0.062)	0.403	(0.068)
FCI: Played with toys	0.175	(0.060)	0.183	(0.060)
FCI: Named things to child	0.137	(0.048)	0.144	(0.048)

Notas: Los valores del artículo corresponden a la Tabla 2 de Attanasio et al. (2020). Errores estándar clusterizados por municipio entre paréntesis.

2. ¿Por qué corregir la inferencia con múltiples hipótesis?

Cada test individual a un nivel α tiene una probabilidad α de rechazar una hipótesis nula verdadera (error de tipo I). Cuando se testean muchas hipótesis a la vez, la probabilidad de cometer *al menos* un error de tipo I crece rápidamente con el número de tests. Si los m tests fueran independientes y todas las nulas fueran ciertas, esa probabilidad sería $1-(1-\alpha)^m$: con $\alpha = 0.05$, es 26% para los 6 outcomes del panel A y 66% para las 21 hipótesis de la tabla. Es decir, si no corregimos, es muy probable encontrar algún efecto "significativo" solo por azar, y el problema se agrava si después se destacan solamente los resultados significativos.

Las correcciones buscan controlar alguna medida del error conjunto. Las dos más usadas son la *family-wise error rate* (FWER), que es la probabilidad de rechazar al menos una nula verdadera dentro de la familia de hipótesis, y la *false discovery rate* (FDR), que es la proporción esperada de falsos rechazos entre todas las hipótesis rechazadas.

3. Corrección de los p-valores

Definimos cada panel de la tabla como una familia de hipótesis (A: 6 hipótesis; B, C y D: 5 cada uno), porque cada panel agrupa outcomes que miden un mismo concepto. Calculamos:

a. **Bonferroni**: $p_j^B = \min\{1,\ m\,p_j\}$. Equivale a testear cada hipótesis a nivel α/m y controla la FWER.

b. **Holm**: se ordenan los p-valores de menor a mayor, $p_{(1)} \leq \cdots \leq p_{(m)}$, y se compara $p_{(k)}$ con $\alpha/(m-k+1)$, deteniéndose en el primer no rechazo. El p-valor ajustado es $p_{(k)}^H = \max_{j \leq k} \min\{1, (m-j+1)\,p_{(j)}\}$. También controla la FWER.

c. **Benjamini, Krieger y Yekutieli (BKY, 2006)**: es un procedimiento en dos etapas que controla la FDR. En la primera etapa se aplica Benjamini–Hochberg a nivel $q' = q/(1+q)$ para estimar el número de hipótesis nulas verdaderas, $\hat{m}_0 = m - r_1$, donde r_1 es la cantidad de rechazos. En la segunda etapa se vuelve a aplicar Benjamini–Hochberg a nivel $q'\,m/\hat{m}_0$. Reportamos los *sharpened q-values* de Anderson (2008), es decir, el menor q al que se rechaza cada hipótesis.

La Tabla 3 repite la tabla del punto 1 y agrega el p-valor original y los tres p-valores corregidos.

Tabla 3: Efectos del tratamiento con p-valores corregidos por múltiples hipótesis

Panel A: habilidades cognitivas del niño

	(1) Cognitive	(2) Receptive lang.	(3) Expressive lang.	(4) Fine motor	(5) Words	(6) Phrases
Treatment	0.250***	0.174***	0.029	0.073	0.086	0.057
	(0.063)	(0.063)	(0.062)	(0.059)	(0.064)	(0.056)
Observaciones	1,263	1,263	1,262	1,261	1,321	1,321
p-valor	0.000	0.007	0.644	0.224	0.179	0.315
Bonferroni	0.001	0.042	1.000	1.000	1.000	1.000
Holm	0.001	0.035	0.716	0.716	0.716	0.716
BKY (q-valor)	0.001	0.018	0.508	0.290	0.290	0.338

Panel B: habilidades socioemocionales del niño

	(1) Difficult (-)	(2) Unsociable (-)	(3) Unstoppable (-)	(4) Inhibitory control	(5) Attentional focusing
Treatment	0.073	0.037	0.031	0.000	0.072
	(0.045)	(0.055)	(0.054)	(0.058)	(0.048)
Observaciones	1,325	1,325	1,325	1,322	1,322
p-valor	0.107	0.506	0.569	1.000	0.136
Bonferroni	0.533	1.000	1.000	1.000	0.681
Holm	0.533	1.000	1.000	1.000	0.545
BKY (q-valor)	0.517	0.744	0.744	1.000	0.517

Panel C: inversiones materiales

	(1) Play materials	(2) Coloring books	(3) Toys movement	(4) Toys shapes	(5) Shop-bought toys
Treatment	0.217***	-0.124**	-0.049	0.426***	0.020
	(0.064)	(0.056)	(0.065)	(0.088)	(0.061)
Observaciones	1,325	1,325	1,325	1,325	1,325
p-valor	0.001	0.028	0.452	0.000	0.750
Bonferroni	0.005	0.140	1.000	0.000	1.000
Holm	0.004	0.084	0.905	0.000	0.905
BKY (q-valor)	0.002	0.029	0.293	0.001	0.429

Panel D: inversiones de tiempo

	(1) Play activities	(2) Told a story	(3) Read to child	(4) Played with toys	(5) Named things
Treatment	0.280***	0.153**	0.403***	0.183***	0.144***
	(0.051)	(0.064)	(0.068)	(0.060)	(0.048)
Observaciones	1,325	1,325	1,325	1,325	1,325
p-valor	0.000	0.019	0.000	0.003	0.004
Bonferroni	0.000	0.095	0.000	0.014	0.018
Holm	0.000	0.019	0.000	0.009	0.009
BKY (q-valor)	0.001	0.005	0.001	0.003	0.003

Notas: Ver notas de la Tabla 1. Las estrellas corresponden al p-valor sin corregir. Las correcciones se aplican dentro de cada panel (familias de 6, 5, 5 y 5 hipótesis). BKY: *sharpened q-values* de Anderson (2008); el valor mínimo posible es 0.001.

4. Similitudes y diferencias entre las estrategias

Bonferroni y Holm controlan la misma tasa de error (FWER) y ambos son válidos bajo cualquier estructura de dependencia entre los tests, así que no requieren suponer independencia. Holm es

una versión secuencial de Bonferroni: el p-valor más chico se ajusta igual que con Bonferroni (multiplicándolo por m), pero los siguientes se multiplican por $m-1$, $m-2$, etc. Por eso los p-valores de Holm nunca son mayores que los de Bonferroni y el procedimiento es más potente sin perder el control de la FWER. BKY, en cambio, controla la FDR, un criterio menos exigente: tolera que una proporción controlada de los rechazos sean falsos, a cambio de más poder. Su validez está demostrada bajo independencia de los tests (y en simulaciones funciona bien con dependencia positiva). Además es adaptativo: si muchas hipótesis de la familia parecen ser falsas, el umbral de la segunda etapa se relaja. Por eso, en familias con muchos efectos reales (como el panel D), los q-valores pueden ser incluso menores que los p-valores originales.

En nuestros resultados se ve justamente ese orden: BKY $\leq$ Holm $\leq$ Bonferroni. Los efectos más fuertes sobreviven a las tres correcciones: Bayley cognitivo y lenguaje receptivo (panel A), tipos de materiales de juego y juguetes para aprender formas (panel C), y tipos de actividades de juego, lectura, juego con juguetes y nombrar cosas (panel D), todos con p-valores corregidos menores a 0.05. Las diferencias aparecen en los resultados más débiles:

- *Libros para colorear* (panel C, $p = 0.028$): deja de ser significativo al 5% con Bonferroni (0.140) y con Holm (0.084, significativo solo al 10%), pero sigue siéndolo con BKY (0.029).
- *Contar un cuento* (panel D, $p = 0.019$): con Bonferroni pasa a ser significativo solo al 10% (0.095), mientras que con Holm (0.019) y BKY (0.005) sigue siendo significativo al 5%.
- En el panel B ningún outcome es significativo antes ni después de corregir.

5. Comparación con los resultados del artículo

El artículo reporta, para cada medida individual, el coeficiente y el error estándar sin ajustar por múltiples hipótesis. Su forma de lidiar con la multiplicidad es resumir cada panel en un factor latente (que nosotros no podemos replicar porque no tenemos esas variables). Nuestros resultados corregidos confirman sus conclusiones principales: el programa mejoró el desarrollo cognitivo (sobre todo la parte cognitiva y el lenguaje receptivo de la escala Bayley) y aumentó las inversiones de los padres, especialmente las de tiempo y algunos materiales de juego específicos. Los efectos individuales que dejan de ser robustos con las correcciones más exigentes son la caída en los libros para colorear y el aumento en contar cuentos. Los ítems socioemocionales no son significativos de manera individual ni en el artículo ni en nuestra replicación; el efecto significativo sobre el factor socioemocional que reporta el artículo surge de agregar los ítems, algo que no podemos evaluar con nuestros datos.

Las conclusiones dependen en parte de cómo se define la familia de hipótesis. Si tratáramos las 21 hipótesis como una sola familia (una opción más conservadora), con Bonferroni y Holm seguirían siendo significativos al 5% el Bayley cognitivo, los tipos de materiales de juego, los juguetes para aprender formas, los tipos de actividades de juego, la lectura y, solo con Holm, el juego con juguetes. Con BKY los resultados prácticamente no cambian: todos los outcomes significativos al 5% con familias por panel lo siguen siendo.

Referencias

Anderson, M. L. (2008). Multiple inference and gender differences in the effects of early intervention: A reevaluation of the Abecedarian, Perry Preschool, and Early Training projects. *Journal of the American Statistical Association*, 103(484), 1481–1495.

Attanasio, O., Cattan, S., Fitzsimons, E., Meghir, C., y Rubio-Codina, M. (2020). Estimating the

production function for human capital: results from a randomized controlled trial in Colombia. *American Economic Review*, 110(1), 48–85.

Benjamini, Y., Krieger, A. M., y Yekutieli, D. (2006). Adaptive linear step-up procedures that control the false discovery rate. *Biometrika*, 93(3), 491–507.

Apéndice: código

```
/*******************************************************************************
                    Problem Set 2: Multiple hypothesis testing

                          Universidad de San Andrés
                              Economía Aplicada
                                   2024
*******************************************************************************/

* Paper: Attanasio, Cattan, Fitzsimons, Meghir y Rubio-Codina (2020), AER 110(1)

/*******************************************************************************
Este archivo sigue la siguiente estructura:

0) Set up environment and globals

1) Labels

2) Regressions (Tabla 2 del paper)

3) Corrections (Bonferroni, Holm y Benjamini-Krieger-Yekutieli)

4) Export tables

*******************************************************************************/


* 0) Set up environment
*==============================================================================*
clear all
set more off
* directorio: completar con la ruta a la carpeta del problem set
gl main ""
gl input "$main/input"
gl output "$main/output"

cap which esttab
if _rc ssc install estout

* Open data set
use "$input/measures.dta", clear

* Global with control variables
global covs_eva "male i.eva_fu"
global covs_ent "male i.ent_fu"

* 1) Labels
*==============================================================================*

label var b_tot_cog1_st "Bayley: Cognitive"
label var b_tot_lr1_st "Bayley: Receptive language"
label var b_tot_le1_st "Bayley: Expressive language"
label var b_tot_mf1_st "Bayley: Fine motor"
label var mac_words1_st "MacArthur: Words the child can say"
label var mac_phrases1_st "MacArthur: Complex phrases the child can say"
label var bates_difficult1_st "ICQ: Difficult(-)"
label var bates_unsociable1_st "ICQ: Unsociable(-)"
label var bates_unstoppable1_st "ICQ: Unstoppable(-)"
label var roth_inhibit1_st "ECBQ: Inhibitory control"
label var roth_attention1_st "ECBQ: Attentional focusing"
label var fci_play_mat_type1_st "FCI: Number of types of play materials"
label var Npaintbooks1_st "FCI: Number of coloring and drawing books"
label var Nthingsmove1_st "FCI: Number of toys to learn movement"
label var Ntoysshape1_st "FCI: Number of toys to learn shapes"
label var Ntoysbought1_st "FCI: Number of shop-bought toys"
label var fci_play_act1_st  "FCI: Number of types of play activities in last 3 days"
label var home_stories1_st "FCI: Number of times told a story to child in last 3 days"
label var home_read1_st "FCI: Number of times read to child in last 3 days"
label var home_toys1_st "FCI: Number of times played with toys in last 3 days"
label var home_name1_st "FCI: Number of times named things to child in last 3 days"
label var treat "Treatment"
```

```
* 2) Regressions
*==============================================================================*

* Cada regresión se guarda como m1, ..., m21 y su p-valor (H0: treat = 0) se
* guarda en la matriz P, junto con el panel al que pertenece (1=A, ..., 4=D).

local bayley "b_tot_cog b_tot_lr b_tot_le b_tot_mf"
local macarthur "mac_words mac_phrases"
local bates "bates_difficult bates_unsociable bates_unstoppable"
local roth "roth_inhibit roth_attention"
local fcimat "fci_play_mat_type Npaintbooks Nthingsmove Ntoysshape Ntoysbought"
local fcitime "fci_play_act home_stories home_read home_toys home_name"

eststo clear
mat P = J(21, 2, .)
local i = 0

*******************************************************************************
* PANEL A (Child's cognitive skills at follow up)
*******************************************************************************

foreach y of local bayley {
    local ++i
    eststo m`i': reg `y'1_st treat `y'0_st $covs_eva, cluster(cod_dane)
    test treat = 0
    mat P[`i',1] = r(p)
    mat P[`i',2] = 1
}

foreach y of local macarthur {
    local ++i
    eststo m`i': reg `y'1_st treat mac_words0_st $covs_ent, cluster(cod_dane)
    test treat = 0
    mat P[`i',1] = r(p)
    mat P[`i',2] = 1
}

*******************************************************************************
* PANEL B (Child's socio-emotional skills at follow up)
*******************************************************************************

foreach y of local bates {
    local ++i
    eststo m`i': reg `y'1_st treat `y'0_st $covs_ent, cluster(cod_dane)
    test treat = 0
    mat P[`i',1] = r(p)
    mat P[`i',2] = 2
}

foreach y of local roth {
    local ++i
    eststo m`i': reg `y'1_st treat bates_difficult0_st $covs_ent, cluster(cod_dane)
    test treat = 0
    mat P[`i',1] = r(p)
    mat P[`i',2] = 2
}

*******************************************************************************
* PANEL C (Material investments)
*******************************************************************************

foreach y of local fcimat {
    local ++i
    eststo m`i': reg `y'1_st treat fci_play_mat_type0_st $covs_ent, cluster(cod_dane)
    test treat = 0
    mat P[`i',1] = r(p)
    mat P[`i',2] = 3
}

*******************************************************************************
* PANEL D (Time investments)
*******************************************************************************
```

```
foreach y of local fcitime {
    local ++i
    eststo m`i': reg `y'1_st treat fci_play_act0_st $covs_ent, cluster(cod_dane)
    test treat = 0
    mat P[`i',1] = r(p)
    mat P[`i',2] = 4
}


* 3) Corrections
*==============================================================================*

* Familia de hipótesis = cada panel de la tabla (A: 6, B: 5, C: 5, D: 5).

preserve
clear
svmat P
rename (P1 P2) (pval panel)
gen outcome = _n

* número de hipótesis de cada familia
bysort panel: gen m = _N

*******************************************************************************
* a. Bonferroni: p ajustado = min(1, m*p)
*******************************************************************************

gen p_bonf = min(1, pval*m)

*******************************************************************************
* b. Holm: se ordenan los p-valores de menor a mayor dentro de cada familia y
*    p ajustado(j) = max_{k<=j} min(1, (m-k+1)*p(k))
*******************************************************************************

bysort panel (pval): gen p_holm = min(1, (m - _n + 1)*pval)
bysort panel (pval): replace p_holm = max(p_holm, p_holm[_n-1]) if _n > 1

*******************************************************************************
* c. Benjamini, Krieger y Yekutieli (2006): sharpened q-values
*    (adaptación del código de Michael Anderson, aplicado dentro de cada familia)
*******************************************************************************

gen q_bky = .
forvalues k = 1/4 {
    quietly count if panel == `k'
    local totalpvals = r(N)

    * ranking de los p-valores dentro de la familia
    gen int rank = .
    bysort panel (pval): replace rank = _n if panel == `k'
    gen bky_tmp = 1 if panel == `k'

    * se chequea qué hipótesis se rechazan con q = 1, 0.999, ..., 0.001
    forvalues s = 1000(-1)1 {
        local qval = `s'/1000

        * Primera etapa: q' = q/(1+q)
        local qval_adj = `qval'/(1+`qval')
        gen fdr_temp1 = `qval_adj'*rank/`totalpvals' if panel == `k'
        gen reject_temp1 = (fdr_temp1 >= pval) if panel == `k'
        gen reject_rank1 = reject_temp1*rank
        egen total_rejected1 = max(reject_rank1)

        * Segunda etapa: q_2st = q'*(M/m0), con m0 = M - rechazadas en la 1ra etapa
        local qval_2st = `qval_adj'*(`totalpvals'/(`totalpvals'-total_rejected1[1]))
        gen fdr_temp2 = `qval_2st'*rank/`totalpvals' if panel == `k'
        gen reject_temp2 = (fdr_temp2 >= pval) if panel == `k'
        gen reject_rank2 = reject_temp2*rank
        egen total_rejected2 = max(reject_rank2)

        * una hipótesis se rechaza al nivel q si su rank es <= al máximo rank rechazado
        replace bky_tmp = `qval' if rank <= total_rejected2 & panel == `k'
```

```
        drop fdr_temp* reject_temp* reject_rank* total_rejected*
    }
    replace q_bky = bky_tmp if panel == `k'
    drop rank bky_tmp
}

sort outcome
list outcome panel pval p_bonf p_holm q_bky, sep(0)
save "$output/pvalues_corregidos.dta", replace
mkmat pval p_bonf p_holm q_bky, matrix(C)
restore

* agregamos los p-valores (originales y corregidos) a cada regresión guardada
forvalues i = 1/21 {
    estadd scalar p_value = C[`i',1] : m`i'
    estadd scalar p_bonf  = C[`i',2] : m`i'
    estadd scalar p_holm  = C[`i',3] : m`i'
    estadd scalar q_bky   = C[`i',4] : m`i'
}


* 4) Export tables
*================================================================================*

local all ""
forvalues i = 1/21 {
    local all "`all' m`i'"
}

* Tabla del punto 1 (las 21 regresiones)
esttab `all' using "$output/Table_4.rtf", se replace label noobs ///
       keep(treat) ///
       cells(b(fmt(3) star) se(par fmt(3))) ///
       star(* 0.10 ** 0.05 *** 0.01) ///
       stats(N, fmt(0) labels("Sample size"))

* Tabla del punto 3 (la misma tabla + p-valores corregidos)
esttab `all' using "$output/Table_4_Corrected.rtf", se replace label noobs ///
       keep(treat) ///
       cells(b(fmt(3) star) se(par fmt(3))) ///
       star(* 0.10 ** 0.05 *** 0.01) ///
       stats(N p_value p_bonf p_holm q_bky, fmt(0 3 3 3 3) ///
       labels("Sample size" "P-value" "Bonferroni" "Holm" "BKY (sharpened q-value)"))

* Versiones LaTeX: un archivo por panel, con los outcomes en las columnas
local A "m1 m2 m3 m4 m5 m6"
local B "m7 m8 m9 m10 m11"
local C "m12 m13 m14 m15 m16"
local D "m17 m18 m19 m20 m21"
local tA `""Cognitive" "Receptive lang." "Expressive lang." "Fine motor" "Words" "Phrases""'
local tB `""Difficult (-)" "Unsociable (-)" "Unstoppable (-)" "Inhibitory control" "Attentional focusing""'
local tC `""Play materials" "Coloring books" "Toys movement" "Toys shapes" "Shop-bought toys""'
local tD `""Play activities" "Told a story" "Read to child" "Played with toys" "Named things""'

foreach p in A B C D {
    esttab ``p'' using "$output/Tabla 1 - Panel `p'.tex", replace booktabs label ///
        keep(treat) b(3) se(3) star(* 0.10 ** 0.05 *** 0.01) nonotes noobs ///
        mtitles(`t`p'') stats(N, fmt(%9.0fc) labels("Observaciones"))
    esttab ``p'' using "$output/Tabla 2 - Panel `p'.tex", replace booktabs label ///
        keep(treat) b(3) se(3) star(* 0.10 ** 0.05 *** 0.01) nonotes noobs ///
        mtitles(`t`p'') stats(N p_value p_bonf p_holm q_bky, fmt(%9.0fc 3 3 3 3) ///
        labels("Observaciones" "p-valor" "Bonferroni" "Holm" "BKY (q-valor)"))
}
```