Problem Set 3: Sesgos e imprecisión

E178: Economía Aplicada — Universidad de San Andrés
Fecha de entrega: 6 de septiembre de 2024

Integrantes: Juan Batalla, Nina Di Costanzo Pereira, Catalina Gallardo e Ignacio Yenarópulos

Ejercicio 1

Trabajamos con un modelo propio. El proceso generador de datos del modelo base es

$$\text{Wage}_i = 3\,\text{Intelligence}_i + 1\,A_i + 2\,B_i + u_i,$$

con $n = 100$, Intelligence $\sim N(100, 20^2)$, $A \sim N(10, 3^2)$, $B \sim N(5, 1)$ y $u \sim N(0, 1)$ (todas redondeadas a enteros con `int()`). En cada punto modificamos un único elemento del modelo y comparamos la regresión resultante con la del modelo base. Como los verdaderos coeficientes son conocidos (3, 1 y 2), podemos evaluar tanto el sesgo como la precisión de las estimaciones. Recordemos que, bajo homocedasticidad, la varianza del estimador de MCO de cada coeficiente es

$$V(\hat{\beta}_j \mid X) = \frac{\sigma^2}{SST_j\,(1 - R_j^2)},$$

donde σ^2 es la varianza del error, $SST_j = \sum_i (x_{ij} - \bar{x}_j)^2$ y R_j^2 es el R^2 de regresar x_j contra los demás regresores. Esta fórmula explica los resultados de los puntos 1, 2, 3 y 6.

1. ¿Qué sucede con los errores estándar si aumenta el tamaño muestral?

Disminuyen. Al aumentar n, SST_j crece aproximadamente en proporción a n, de modo que el error estándar cae a una tasa de $1/\sqrt{n}$. En la Tabla 1, al pasar de 100 a 1000 observaciones los errores estándar se reducen aproximadamente a un tercio ($1/\sqrt{10} \approx 0.32$): el de *Intelligence* pasa de 0.0036 a 0.0010, el de A de 0.025 a 0.007 y el de B de 0.060 a 0.019. Los coeficientes estimados, a su vez, quedan aún más cerca de sus valores verdaderos.

Tabla 1: Aumento del tamaño muestral

	(1) Wage	(2) Wage
Intelligence	3.001***	3.000***
	(0.00361)	(0.00102)
A	0.987***	0.998***
	(0.0246)	(0.00667)
B	2.012***	1.995***
	(0.0595)	(0.0185)
Constant	-0.0615	0.0271
	(0.506)	(0.149)
Observations	100	1000

Notas: Columna (1): modelo base ($n = 100$). Columna (2): $n = 1000$. Errores estándar entre paréntesis. * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.

2. ¿Qué sucede con los errores estándar si aumenta la varianza de μ?

Aumentan, porque σ^2 está en el numerador de la varianza del estimador: con más ruido en el término de error, los datos contienen menos información sobre los parámetros. En la Tabla 2, al pasar el desvío del error de 1 a 10, el error estándar de *Intelligence* pasa de 0.0036 a 0.051, el de A de 0.025 a 0.351 y el de B de 0.060 a 0.848. Las estimaciones puntuales también se alejan más de los valores verdaderos (por ejemplo, 0.855 para A y 2.849 para B), aunque los estimadores siguen siendo insesgados. El coeficiente de A pasa a ser significativo solo al 5%.

Tabla 2: Aumento de la varianza del término de error

	(1) Wage	(2) Wage
Intelligence	3.001***	3.044***
	(0.00361)	(0.0514)
A	0.987***	0.855*
	(0.0246)	(0.351)
B	2.012***	2.849**
	(0.0595)	(0.848)
Constant	-0.0615	-7.096
	(0.506)	(7.203)
Observations	100	100

Notas: Columna (1): modelo base, $u \sim N(0,1)$. Columna (2): $u \sim N(0,10^2)$. Errores estándar entre paréntesis. * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.

3. ¿Qué sucede con el error estándar de un regresor si aumenta la varianza de X?

Disminuye, porque SST_j está en el denominador: cuanto más varía el regresor, más información hay para identificar su efecto sobre Y. En la Tabla 3 aumentamos el desvío de *Intelligence* de 20 a 50 y su error estándar cae de 0.0036 a 0.0015, en la proporción $20/50 = 0.4$. Los errores estándar de A y B prácticamente no cambian, porque su variabilidad no se modificó.

Tabla 3: Aumento de la varianza de un regresor

	(1) Wage	(2) Wage
Intelligence	3.001***	3.000***
	(0.00361)	(0.00145)
A	0.987***	0.987***
	(0.0246)	(0.0246)
B	2.012***	2.012***
	(0.0595)	(0.0596)
Constant	-0.0615	0.00847
	(0.506)	(0.367)
Observations	100	100

Notas: Columna (1): modelo base, Intelligence $\sim N(100, 20^2)$. Columna (2): Intelligence $\sim N(100, 50^2)$. Errores estándar entre paréntesis. * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.

4. ¿Cuánto vale la suma de los residuos?

Si el modelo incluye una constante, la suma de los residuos de MCO es exactamente cero. Es una de las condiciones de primer orden del problema de minimización: la derivada de $\sum_i \hat{u}_i^2$ respecto de la constante es $-2\sum_i \hat{u}_i = 0$. En el modelo base la suma es 1.04×10^{-7} (Tabla 4), que es cero salvo por errores de redondeo numérico.

Tabla 4: Suma de los residuos del modelo base

	Suma
Residuals	1.04e-07

5. ¿Son los residuos ortogonales a los regresores?

Sí. Las condiciones de primer orden de MCO (las ecuaciones normales) son $X'\hat{u} = 0$, es decir, $\sum_i x_{ij}\hat{u}_i = 0$ para cada regresor j. Como además los residuos tienen media cero, la correlación muestral entre los residuos y cada regresor es exactamente cero. La Tabla 5 lo confirma: las correlaciones de los residuos con *Intelligence*, A y B son 0.000. Entre los regresores hay correlaciones bajas que surgen solo por azar (por ejemplo, 0.151 entre A y B), ya que los generamos de forma independiente.

Tabla 5: Correlaciones entre los residuos y los regresores

	Residuals	Intelligence	A	B
Residuals	1.000	0.000	0.000	0.000
Intelligence	0.000	1.000	-0.085	-0.119
A	0.000	-0.085	1.000	0.151
B	0.000	-0.119	0.151	1.000

6. ¿Cómo afecta la alta multicolinealidad a la estimación de Y?

Para estudiarlo generamos *Education* = *Intelligence* + $N(0,1)$, que tiene una correlación de casi 1 con *Intelligence* pero no entra en el verdadero modelo de *Wage*, y la agregamos a la regresión (Tabla 6). La multicolinealidad no genera sesgo, pero aumenta mucho la varianza de los coeficientes de las variables colineales, porque R_j^2 se acerca a 1: el error estándar de *Intelligence* pasa de 0.0036 a 0.074, unas 20 veces más grande. Lo que el modelo no puede hacer es separar el efecto de cada una de las dos variables colineales.

En cambio, la estimación (predicción) de Y prácticamente no se ve afectada. Como *Intelligence* y *Education* se mueven casi juntas, lo que importa para predecir es la suma de sus coeficientes, $2.932 + 0.072 = 3.004$, que es casi idéntica al verdadero efecto de 3 y está estimada con mucha precisión. Es decir, la multicolinealidad afecta la precisión de los coeficientes individuales, pero no la capacidad del modelo de predecir Y (siempre que la relación entre las variables colineales se mantenga).

Tabla 6: Alta multicolinealidad

	(1) Wage	(2) Wage
Intelligence	3.001***	2.932***
	(0.00361)	(0.0736)
A	0.987***	1.022***
	(0.0246)	(0.0198)
B	2.012***	1.976***
	(0.0595)	(0.0653)
Education		0.0719
		(0.0737)
Constant	-0.0615	-0.479
	(0.506)	(0.470)
Observations	100	100

Notas: Columna (1): modelo base. Columna (2): modelo que agrega *Education*, con correlación cercana a 1 con *Intelligence*. Como generar *Education* usa números aleatorios adicionales, la muestra de la columna (2) no es idéntica a la del modelo base. Errores estándar entre paréntesis. * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.

7. Error no aleatorio y error aleatorio en X

Error no aleatorio. Medimos la inteligencia con un error sistemático constante: $\widetilde{\text{Intelligence}} = \text{Intelligence} + 5$. Como $\text{Wage} = 3(\widetilde{\text{Intelligence}} - 5) + A + 2B + u = -15 + 3\,\widetilde{\text{Intelligence}} + A + 2B + u$, el error constante solo se traslada a la constante: los coeficientes de las pendientes y sus errores estándar son idénticos a los del modelo base, y la constante cae exactamente en $3 \times 5 = 15$ (de -0.06 a -15.07; columna 2 de la Tabla 7). Si el error sistemático no fuera constante (por ejemplo, si estuviera correlacionado con otras variables), sí sesgaría las pendientes.

Error aleatorio. Si $\widetilde{\text{Intelligence}} = \text{Intelligence} + e$ con $e \sim N(0, 5^2)$ independiente de todo lo demás (error de medición clásico), el estimador de MCO es sesgado e inconsistente. El regresor observado queda correlacionado con el término de error compuesto $(u - 3e)$ y el coeficiente se

sesga hacia cero (sesgo de atenuación):

$$\operatorname{plim} \hat{\beta}_1 = \beta_1 \frac{\sigma^2_{\text{Int}}}{\sigma^2_{\text{Int}} + \sigma^2_e} = 3 \times \frac{400}{425} \approx 2.82.$$

En la columna 3 el coeficiente estimado es 2.741, menor que 3. Además, como el error de medición pasa al término de error, la varianza residual aumenta mucho: los errores estándar crecen, A y B dejan de ser significativos y la constante también queda sesgada (34.92).

Tabla 7: Error no aleatorio y error aleatorio en el regresor

	(1) Wage	(2) Wage	(3) Wage
Intelligence	3.001***	3.001***	2.741***
	(0.00361)	(0.00361)	(0.0728)
A	0.987***	0.987***	0.619
	(0.0246)	(0.0246)	(0.527)
B	2.012***	2.012***	0.215
	(0.0595)	(0.0595)	(1.270)
Constant	-0.0615	-15.07***	34.92**
	(0.506)	(0.520)	(10.33)
Observations	100	100	100

Notas: Columna (1): modelo base. Columna (2): *Intelligence* medida con error constante (+5). Columna (3): *Intelligence* medida con error aleatorio $N(0, 5^2)$. Errores estándar entre paréntesis. * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.

8. Error no aleatorio y error aleatorio en Y

Error no aleatorio. Si la variable dependiente se mide con un error constante ($\widetilde{\text{Wage}} = \text{Wage} + 10$), el error vuelve a absorberse en la constante. Las pendientes y sus errores estándar no cambian y la constante aumenta exactamente en 10 (de -0.06 a 9.94; columna 2 de la Tabla 8).

Error aleatorio. Si $\widetilde{\text{Wage}} = \text{Wage} + v$ con $v \sim N(0, 5^2)$ independiente de los regresores, el error de medición simplemente se suma al término de error. Los estimadores siguen siendo insesgados y consistentes, pero menos precisos, porque aumenta la varianza del error. En la columna 3 los coeficientes siguen cerca de los verdaderos valores (3.027, 1.088 y 2.544, este último dentro de su intervalo de confianza), pero los errores estándar son mucho más grandes (por ejemplo, 0.027 contra 0.0036 para *Intelligence*). A diferencia del error en X, el error de medición aleatorio en Y no genera sesgo.

Tabla 8: Error no aleatorio y error aleatorio en la variable dependiente

	(1) Wage	(2) Wage (Non-Random Error)	(3) Wage (Random Error)
Intelligence	3.001***	3.001***	3.027***
	(0.00361)	(0.00361)	(0.0274)
A	0.987***	0.987***	1.088***
	(0.0246)	(0.0246)	(0.188)
B	2.012***	2.012***	2.544***
	(0.0595)	(0.0595)	(0.453)
Constant	-0.0615	9.938***	-5.334
	(0.506)	(0.506)	(3.849)
Observations	100	100	100

Notas: Columna (1): modelo base. Columna (2): *Wage* medido con error constante (+10). Columna (3): *Wage* medido con error aleatorio $N(0, 5^2)$. Errores estándar entre paréntesis. * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.

Ejercicio 2

Comparamos $\tilde{\beta}_1$, de la regresión simple de *score* en *attend*, con $\hat{\beta}_1$, de la regresión que además controla por *cgpa* y *study*. La relación entre ambos está dada por la fórmula del sesgo por variable omitida:

$$\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2\,\tilde{\delta}_2 + \hat{\beta}_3\,\tilde{\delta}_3,$$

donde $\tilde{\delta}_j$ es el coeficiente de regresar X_j contra X_1. Es decir, $\tilde{\beta}_1$ y $\hat{\beta}_1$ difieren solo si las variables omitidas afectan a Y ($\hat{\beta}_j \neq 0$) *y* están correlacionadas con X_1 ($\tilde{\delta}_j \neq 0$).

1. X_1 muy correlacionada con X_2 y X_3, que tienen mucha relación con Y

Esperamos que sean distintos. Se cumplen las dos condiciones para que haya sesgo por variable omitida: $\tilde{\beta}_1$ capta, además del efecto de la asistencia, parte del efecto del promedio y de las horas de estudio. Si, como es razonable, la asistencia está positivamente correlacionada con el promedio y con las horas de estudio, y estas tienen un efecto positivo sobre la nota, $\tilde{\beta}_1$ sobreestima el efecto de la asistencia ($\tilde{\beta}_1 > \hat{\beta}_1$).

2. X_1 no correlacionada con X_2 y X_3, pero X_2 y X_3 muy correlacionadas entre sí

Esperamos que sean similares. Como X_1 no está correlacionada con X_2 ni con X_3, $\tilde{\delta}_2 \approx \tilde{\delta}_3 \approx 0$ y omitirlas no sesga el coeficiente de la asistencia, aunque afecten a Y. La alta correlación entre X_2 y X_3 solo vuelve imprecisos los coeficientes de esas dos variables, pero no afecta a $\hat{\beta}_1$.

3. $\dot{\beta}_1$: se agrega el consumo de chocolate (X_4)

Es razonable suponer que, una vez que controlamos por asistencia, promedio y horas de estudio, el consumo de chocolate no afecta la nota de matemática. En ese caso X_4 es una variable irrelevante y su inclusión no sesga los demás coeficientes, por lo que esperamos $\dot{\beta}_1 \approx \hat{\beta}_1$. Esto es así aunque el chocolate esté correlacionado con la asistencia: para que $\hat{\beta}_1$ estuviera sesgado por omitir X_4, el

chocolate tendría que afectar a Y *y* estar correlacionado con X_1. Solo en ese caso (poco plausible) esperaríamos $\dot{\beta}_1 \neq \hat{\beta}_1$.

4. X_1 muy correlacionada con X_2 y X_3, que tienen poca relación con Y

Esperamos que sean similares. Aunque $\tilde{\delta}_2$ y $\tilde{\delta}_3$ son grandes, $\hat{\beta}_2$ y $\hat{\beta}_3$ son cercanos a cero, así que el sesgo por omitirlas es pequeño. La diferencia está en la precisión: en la regresión múltiple, R_1^2 (el R^2 de regresar X_1 contra X_2 y X_3) es alto, lo que aumenta la varianza de $\hat{\beta}_1$, y como X_2 y X_3 casi no explican Y, tampoco reducen la varianza del error. Por eso $\hat{\beta}_1$ será bastante menos preciso que $\tilde{\beta}_1$.

5. Errores estándar: X_1 no correlacionada con X_2 y X_3, que tienen grandes efectos sobre Y y están muy correlacionadas entre sí

Esperamos que el error estándar de $\hat{\beta}_1$ sea menor que el de $\tilde{\beta}_1$. Al incluir X_2 y X_3, que explican mucho de Y, cae la varianza del error (σ^2, en el numerador). Como X_1 no está correlacionada con ellas, $R_1^2 \approx 0$ y no hay costo por multicolinealidad para $\hat{\beta}_1$. La alta correlación entre X_2 y X_3 solo infla los errores estándar de $\hat{\beta}_2$ y $\hat{\beta}_3$. Ambos estimadores son insesgados (punto 2), pero $\hat{\beta}_1$ es más preciso.

6. Errores estándar de $\dot{\beta}_1$ y $\hat{\beta}_1$

Depende de los supuestos sobre el chocolate:

- Si el chocolate no afecta a Y y no está correlacionado con la asistencia (el caso más razonable), los errores estándar serán prácticamente iguales; el de $\dot{\beta}_1$ será apenas mayor por la pérdida de un grado de libertad.
- Si el chocolate no afecta a Y pero está correlacionado con la asistencia (o con X_2 y X_3), incluirlo aumenta R_1^2 sin reducir σ^2, de modo que el error estándar de $\dot{\beta}_1$ será mayor que el de $\hat{\beta}_1$.
- Si el chocolate sí afecta a Y y no está correlacionado con la asistencia, incluirlo reduce σ^2 y el error estándar de $\dot{\beta}_1$ será menor.
- Si el chocolate afecta a Y y está correlacionado con la asistencia, hay dos efectos opuestos (menor σ^2, mayor R_1^2) y el resultado es ambiguo; además, en ese caso $\hat{\beta}_1$ estaría sesgado.

Apéndice: código

```
/*******************************************************************************
                              Problem Set 3

                        Universidad de San Andrés
                            Economía Aplicada
                                 2024
*******************************************************************************/

clear all
set more off

* directorio: completar con la ruta a la carpeta del problem set
global main ""
global input "$main/input"
global output "$main/output"

* paquetes necesarios (se instalan solo si no están)
foreach pkg in estout asdoc {
    cap which `pkg'
    if _rc ssc install `pkg'
}

*==============================================================================*
* EJERCICIO 1
*==============================================================================*

set obs 100
set seed 1233

gen Intelligence = int(rnormal(100,20))
gen A = int(rnormal(10,3))
gen B = int(rnormal(5,1))
gen u = int(rnormal(0,1))
gen Wage = 3*Intelligence + A + 2*B + u

reg Wage Intelligence A B
est store reg_base

*_____________________________________(1)_____________________________________*

clear
set obs 1000 // Aumentamos el tamaño muestral a 1000
set seed 1233

gen Intelligence = int(rnormal(100,20))
gen A = int(rnormal(10,3))
gen B = int(rnormal(5,1))
gen u = int(rnormal(0,1))
gen Wage = 3*Intelligence + A + 2*B + u

reg Wage Intelligence A B
est store reg_1
esttab reg_base reg_1 using "$output/Tabla 1.rtf", replace se label ///
addnotes("Model 1 is the original regression. Model 2 is the regression with an increased sample size.")


esttab reg_base reg_1 using "$output/Tabla 1.tex", replace se label booktabs nonotes
*_____________________________________(2)_____________________________________*

clear
set obs 100
set seed 1233

gen Intelligence = int(rnormal(100,20))
gen A = int(rnormal(10,3))
gen B = int(rnormal(5,1))
gen u = int(rnormal(0,10)) // Aumentamos la varianza del término de error
gen Wage = 3*Intelligence + A + 2*B + u

reg Wage Intelligence A B
est store reg_2
```

```
esttab reg_base reg_2 using "$output/Tabla 2.rtf", replace se label ///
addnotes("Model 1 is the original regression. Model 2 is the regression with increased variance in the
     error term.")


esttab reg_base reg_2 using "$output/Tabla 2.tex", replace se label booktabs nonotes
*_____________________________________(3)_____________________________________*

clear
set obs 100
set seed 1233

gen Intelligence = int(rnormal(100,50)) // Aumentamos la varianza de intelligence
gen A = int(rnormal(10,3))
gen B = int(rnormal(5,1))
gen u = int(rnormal(0,1))
gen Wage = 3*Intelligence + A + 2*B + u

reg Wage Intelligence A B
est store reg_3
esttab reg_base reg_3 using "$output/Tabla 3.rtf", replace se label ///
addnotes("Model 1 is the original regression. Model 2 is the regression with increased variance in
     Intelligence.")


esttab reg_base reg_3 using "$output/Tabla 3.tex", replace se label booktabs nonotes
*_____________________________________(4)_____________________________________*

*Usando el modelo original
clear
set obs 100
set seed 1233

gen Intelligence = int(rnormal(100,20))
gen A = int(rnormal(10,3))
gen B = int(rnormal(5,1))
gen u = int(rnormal(0,1))
gen Wage = 3*Intelligence + A + 2*B + u

reg Wage Intelligence A B
predict Residuals, residuals
estpost tabstat Residuals, listwise ///
stats(sum)
esttab using "$output/Tabla 4.rtf", cells("sum") collabels("Sum") ///
label replace
esttab using "$output/Tabla 4.tex", cells("sum(fmt(%12.2e))") collabels("Suma") ///
label replace booktabs nonumber noobs

*_____________________________________(5)_____________________________________*

asdoc pwcorr Residuals Intelligence A B, save($output/Tabla 5.rtf) replace
* versión LaTeX de la matriz de correlaciones
quietly correlate Residuals Intelligence A B
matrix C = r(C)
esttab matrix(C, fmt(3)) using "$output/Tabla 5.tex", replace booktabs nomtitles

*_____________________________________(6)_____________________________________*

clear
set obs 100
set seed 1233

gen Intelligence = int(rnormal(100,20))
gen Education = Intelligence + rnormal(0,1) // Genero la var education con una alta correlación con
     intelligence
corr Intelligence Education
gen A = int(rnormal(10,3))
gen B = int(rnormal(5,1))
gen u = int(rnormal(0,1))
gen Wage = 3*Intelligence + A + 2*B + u

reg Wage Intelligence Education A B
est store reg_6
```

```
esttab reg_base reg_6 using "$output/Tabla 6.rtf", replace se label ///
addnotes("Model 1 is the original regression. Model 2 is the regression with high multicollinearity as it
     adds the variable Education.")


esttab reg_base reg_6 using "$output/Tabla 6.tex", replace se label booktabs nonotes
*_____________________________________(7)_____________________________________*

clear
set obs 100
set seed 1233

gen intelligence = int(rnormal(100,20))
gen A = int(rnormal(10,3))
gen B = int(rnormal(5,1))
gen u = int(rnormal(0,1))
gen Wage = 3*intelligence + A + 2*B + u

*Error no aleatorio en X
gen intelligence_error = intelligence + 5 // Agregamos error no aleatorio en X
preserve
rename intelligence_error Intelligence
reg Wage Intelligence A B
est store reg_7_1
restore

*Error aleatorio en X
gen intelligence_random_error = intelligence + rnormal(0,5) // Agregamos error aleatorio en X
preserve
rename intelligence_random_error Intelligence
reg Wage Intelligence A B
est store reg_7_2
restore

esttab reg_base reg_7_1 reg_7_2 using "$output/Tabla 7.rtf", replace se label ///
addnotes("Model 1 is the original regression. Model 2 is the regression with a non-random error in
     Intelligence. Model 3 is the regression with a random error in Intelligence.")


esttab reg_base reg_7_1 reg_7_2 using "$output/Tabla 7.tex", replace se label booktabs nonotes
*_____________________________________(8)_____________________________________*

clear
set obs 100
set seed 1233

gen Intelligence = int(rnormal(100,20))
gen A = int(rnormal(10,3))
gen B = int(rnormal(5,1))
gen u = int(rnormal(0,1))
gen wage = 3*Intelligence + A + 2*B + u

// Error no aleatorio en Y
gen wage_nonrandom_error = wage + 10 // Agregamos error no aleatorio en Y
label var wage_nonrandom_error "Wage (Non-Random Error)"
reg wage_nonrandom_error Intelligence A B
est store reg_8_1

// Error aleatorio en Y
gen wage_random_error = wage + rnormal(0,5) // Agregamos error aleatorio en Y
label var wage_random_error "Wage (Random Error)"
reg wage_random_error Intelligence A B
est store reg_8_2

esttab reg_base reg_8_1 reg_8_2 using "$output/Tabla 8.rtf", replace se label ///
addnotes("Model 1 is the original regression. Model 2 is the regression with a non-random error in Y. Model
      3 is the regression with a random error in Y.")

esttab reg_base reg_8_1 reg_8_2 using "$output/Tabla 8.tex", replace se label booktabs nonotes
```