Problem Set 9: Power calculations

E178: Economía Aplicada — Universidad de San Andrés
Fecha de entrega: 15 de noviembre de 2024

Integrantes: Juan Batalla, Nina Di Costanzo Pereira, Catalina Gallardo e Ignacio Yenarópulos

Siguiendo la clase tutorial, simulamos una población de 15,000 empresas con ganancias $G_i \sim N(10000, 2000^2)$ e impuestos pagados $Y_i = 0.2\,G_i + \varepsilon_i$. Para cada tamaño de muestra (de 1,000 a 10,000) y cada efecto (1%, 2.5%, 5%, 7.5% y 10% de aumento en los impuestos de los tratados), sacamos 500 muestras, asignamos el tratamiento al azar, estimamos $Y_i = \alpha + \tau T_i + u_i$ con errores robustos y calculamos el poder como la proporción de muestras en las que rechazamos $H_0 : \tau = 0$ con un test a una cola al 5% ($t > 1.65$).

Los resultados se pueden entender con la fórmula del poder. Si σ es el desvío del término de error, N el tamaño de muestra y p la proporción de tratados, el error estándar del estimador es

$$SE(\hat{\tau}) = \frac{\sigma}{\sqrt{N\,p\,(1-p)}} \qquad \text{y} \qquad \text{Poder} \approx \Phi\left(\frac{\tau}{SE(\hat{\tau})} - z_{0.95}\right),$$

con $z_{0.95} = 1.65$. El poder aumenta con el tamaño del efecto y con N, disminuye con σ, y es máximo cuando $p = 0.5$.

1. Gráfico de la tutorial

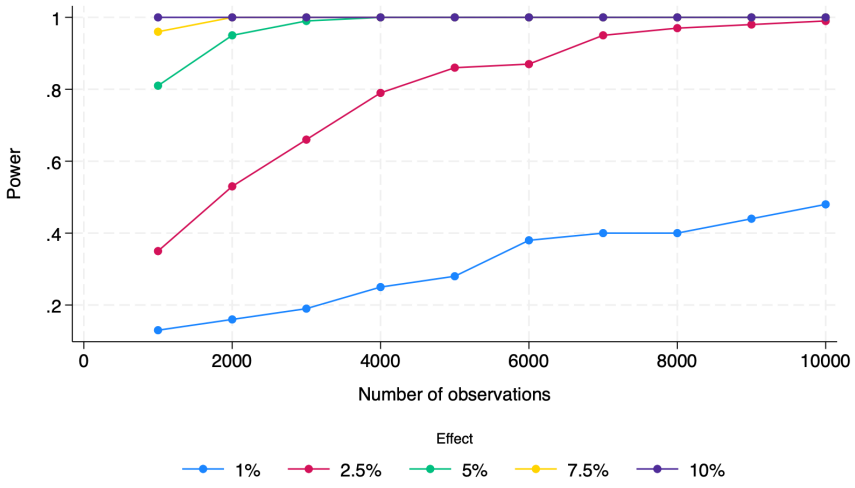


Figura 1: Poder según el tamaño de muestra y el tamaño del efecto (desvío del error = 500).

La Figura 1 muestra que el poder aumenta con el número de observaciones, porque el error estándar cae a una tasa $1/\sqrt{N}$, y que es mayor cuanto más grande es el efecto, porque un efecto mayor es más fácil de distinguir del ruido. Con efectos de 5% o más el poder es prácticamente 1 a partir de 2,000–3,000 observaciones. En cambio, para detectar un efecto de 2.5% con un poder de 80% se necesitan alrededor de 4,000 observaciones, y con un efecto de 1% el poder no llega a 50% ni siquiera con 10,000 observaciones. Los valores simulados coinciden con la fórmula. Por ejemplo, con un efecto de 2.5% (50 pesos sobre impuestos promedio de 2,000) y 2,000 observaciones, el desvío de Y es $\sqrt{400^2 + 500^2} \approx 640$, el error estándar es $640/\sqrt{2000 \times 0.25} \approx 28.6$ y el poder teórico es $\Phi(50/28.6 - 1.65) \approx 0.54$, igual al de la simulación.

2. Varianza del error igual a 5,000

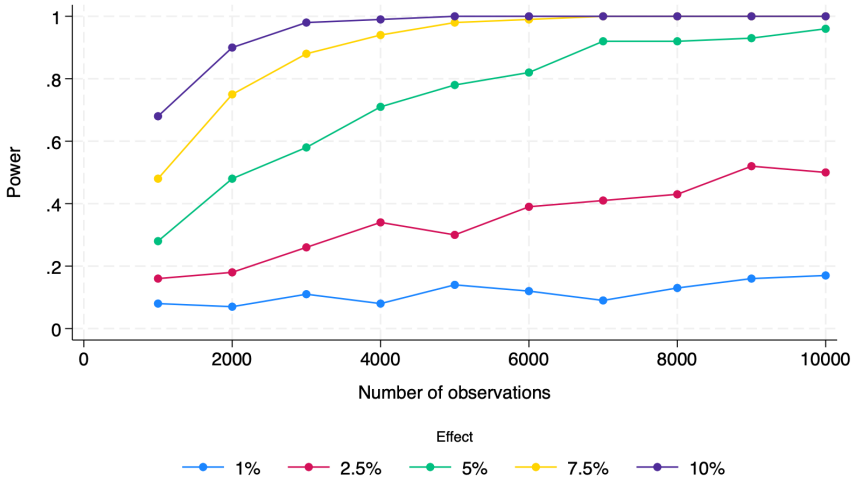
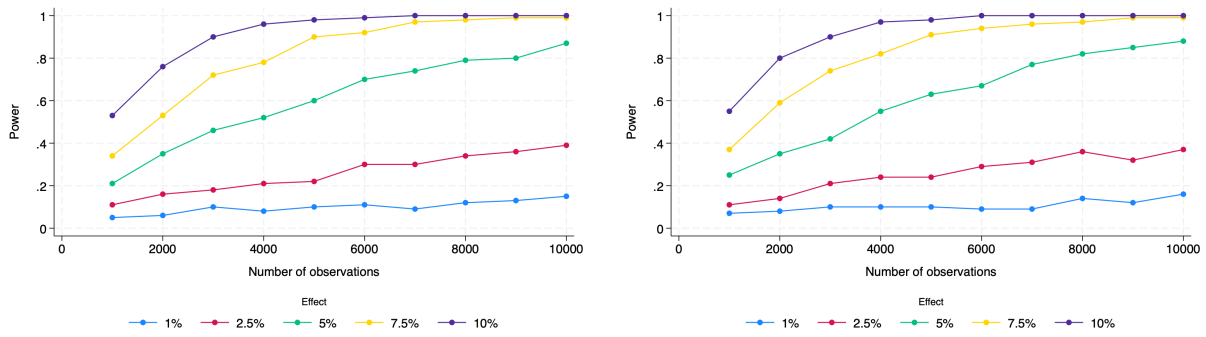


Figura 2: Poder con desvío del error igual a 5,000.

Al aumentar la dispersión del término de error, el outcome tiene mucho más ruido que no explica el tratamiento, el error estándar del estimador aumenta y el poder cae para cualquier tamaño de muestra y de efecto (Figura 2). Ahora un efecto de 5% necesita alrededor de 6,000 observaciones para alcanzar un poder de 80%, y los efectos de 1% y 2.5% tienen poder muy bajo incluso con 10,000 observaciones.

Hay dos detalles del código (que mantuvimos igual al de la tutorial) que conviene aclarar. Primero, `rnormal(0,5000)` fija el *desvío* estándar del error en 5,000, no la varianza. Segundo, al eliminar las observaciones con impuestos negativos se descarta alrededor de un tercio de la población, y las que quedan tienen impuestos promedio de unos 4,800, con un desvío de unos 3,400. Como el efecto es proporcional a los impuestos, el efecto en pesos es mayor que en la simulación original, y por eso el poder no cae tanto como sugeriría multiplicar el desvío del error por diez. Con estos valores la fórmula vuelve a reproducir la simulación: un efecto de 10% con 1,000 observaciones tiene un poder teórico de 0.72 (0.68 en la simulación).

3. Asignación del tratamiento al 20% y al 80% de las observaciones



(a) 20% de tratados

(b) 80% de tratados

Figura 3: Poder con desvío del error igual a 5,000 y distintas proporciones de tratados.

Con el mismo tamaño de muestra, asignar el tratamiento a una proporción distinta de 50% reduce el poder (Figura 3, comparada con la Figura 2). El motivo es que la varianza del estimador es proporcional a $1/[p(1-p)]$: con $p = 0.5$, $p(1-p) = 0.25$, mientras que con $p = 0.2$ o $p = 0.8$, $p(1-p) = 0.16$, de modo que el error estándar es un 25% mayor. Intuitivamente, la diferencia de medias se estima con menos precisión porque uno de los dos grupos es chico. Por ejemplo, con un efecto de 5% y 2,000 observaciones el poder cae de alrededor de 0.48 a 0.35. Como $p(1-p)$ es simétrico, asignar el 20% o el 80% al tratamiento da teóricamente el mismo poder, y las dos figuras son, en efecto, muy parecidas; las pequeñas diferencias se deben al azar de la simulación (y a que, con un efecto proporcional, la varianza del grupo tratado es apenas mayor).

4. Agregar las ganancias estimadas como control

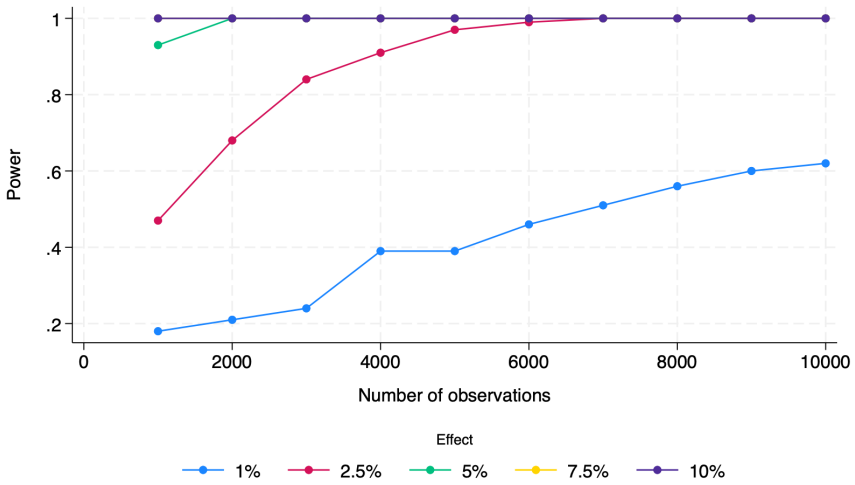


Figura 4: Poder con desvío del error igual a 500, controlando por las ganancias estimadas.

Al controlar por las ganancias estimadas el poder aumenta respecto de la Figura 1 (Figura 4). Las ganancias explican una parte importante de la variación de los impuestos ($0.2\,G_i$ tiene un desvío de 400), así que al incluirlas como control esa variación deja de estar en el término de error. El desvío residual cae de ≈ 640 a 500, el error estándar de $\hat{\tau}$ se reduce alrededor de un 22% y el estadístico t aumenta en la misma proporción. Como el tratamiento es aleatorio, el control no está correlacionado con T, de modo que no cambia el valor esperado de $\hat{\tau}$, solo lo hace más preciso. Por ejemplo, con un efecto de 2.5% y 2,000 observaciones el poder sube de 0.53 a alrededor de 0.68, y con un efecto de 1% y 10,000 observaciones de 0.48 a 0.62.

Apéndice: código

```
/*******************************************************************************
                              Problem Set 9

                          Universidad de San Andrés
                              Economía Aplicada
                                   2024
*******************************************************************************/

clear all
set more off

* directorio: completar con la ruta a la carpeta del problem set
global main ""
global input "$main/input"
global output "$main/output"
cd "$output"

* Nota: rnormal(m, s) toma como segundo argumento el DESVÍO estándar. Siguiendo
* la tutorial, "varianza del error = 500" corresponde a rnormal(0,500) y
* "varianza = 5000" a rnormal(0,5000). Además, como en la tutorial, se eliminan
* las observaciones con impuestos negativos; con desvío 5000 esto descarta
* alrededor de un tercio de la población simulada.

*==============================================================================*

* 1) Grafico

set matsize 600
set seed 123
set obs 15000
gen ganancias_estimadas = rnormal(10000,2000)
drop if ganancias_estimadas<0
gen impuestos_pagados = 0.2*ganancias_estimadas + rnormal(0,500)
drop if impuestos_pagados<0
gen obs=_n
pctile escuela = obs, nq(10)

local i=1
mat resultados = J(50,4,.)

foreach efecto in 0.01 0.025 0.05 0.075 0.1{
    forvalues size = 1000(1000)10000 {
        mat R = J(500,2,.)

            forvalues x=1(1)500 {
                preserve
                sample `size' , count
                gen temp = runiform()
                gen T=0
                replace T = 1 if temp<0.5
                replace impuestos_pagados = impuestos_pagados * (1+`efecto') if T==1
                reg impuestos_pagados T, robust
                mat R[`x',1]=_b[T]/_se[T]
                restore
            }

    preserve
    clear
    svmat R
    gen reject = 0
    replace reject = 1 if (R1>1.65)
    drop if reject==.
    sum reject
    scalar media = r(mean)

    mat resultados[`i',3] = `efecto'
    mat resultados[`i',2] = media
    mat resultados[`i',1] = `size'
    restore

    local i=`i'+1
```

```
    }
}

clear
svmat resultados
rename resultados1 sample_size
rename resultados2 st_power
rename resultados3 efecto
replace st_power=round(st_power,.01)
separate st_power, by(efecto)

twoway (connected st_power1 sample_size) (connected st_power2 sample_size) ///
(connected st_power3 sample_size) (connected st_power4 sample_size) ///
(connected st_power5 sample_size), ytitle("Power") ///
xtitle("Number of observations") ///
legend(label(1 "1%") label(2 "2.5%") label(3 "5%") label(4 "7.5%") label(5 "10%")) ///
legend(rows(1) title("Effect", size(small)) pos(6) ring(1)) xscale(titlegap(3)) yscale(titlegap(3))
graph export "$output/Figura 1.png", replace

*================================================================================*

* 2) Simulacion: distinta varianza

clear all
set seed 123
set obs 15000
gen ganancias_estimadas = rnormal(10000,2000)
drop if ganancias_estimadas<0
gen impuestos_pagados = 0.2*ganancias_estimadas + rnormal(0,5000) // cambiamos la varianza del error a 5000
drop if impuestos_pagados<0
gen obs=_n
pctile escuela = obs, nq(10)

local i=1
mat resultados = J(50,4,.)
foreach efecto in 0.01 0.025 0.05 0.075 0.1{
    forvalues size = 1000(1000)10000 {
        mat R = J(500,2,.)

            forvalues x=1(1)500 {
                preserve
                sample `size' , count
                gen temp = runiform()
                gen T=0
                replace T = 1 if temp<0.5
                replace impuestos_pagados = impuestos_pagados * (1+`efecto') if T==1
                reg impuestos_pagados T, robust
                mat R[`x',1]=_b[T]/_se[T]
                restore
            }

    preserve
    clear
    svmat R
    gen reject = 0
    replace reject = 1 if (R1>1.65)
    drop if reject==.
    sum reject
    scalar media = r(mean)

    mat resultados[`i',3] = `efecto'
    mat resultados[`i',2] = media
    mat resultados[`i',1] = `size'
    restore

    local i=`i'+1
    }
}

clear
svmat resultados
rename resultados1 sample_size
rename resultados2 st_power
```

```
rename resultados3 efecto
replace st_power=round(st_power,.01)
separate st_power, by(efecto)

twoway (connected st_power1 sample_size) (connected st_power2 sample_size) ///
(connected st_power3 sample_size) (connected st_power4 sample_size) ///
(connected st_power5 sample_size), ytitle("Power") ///
xtitle("Number of observations") ///
legend(label(1 "1%") label(2 "2.5%") label(3 "5%") label(4 "7.5%") label(5 "10%")) ///
legend(rows(1) title("Effect", size(small)) pos(6) ring(1)) xscale(titlegap(3)) yscale(titlegap(3))
graph export "$output/Figura 2.png", replace

*================================================================================*

* 3) Simulaciones: distinto porcentaje tratados

*20% de tratados
clear all
set seed 123
set obs 15000
gen ganancias_estimadas = rnormal(10000,2000)
drop if ganancias_estimadas<0
gen impuestos_pagados = 0.2*ganancias_estimadas + rnormal(0,5000) // cambiamos la varianza del error a 5000
drop if impuestos_pagados<0
gen obs=_n
pctile escuela = obs, nq(10)

local i=1
mat resultados = J(50,4,.)
foreach efecto in 0.01 0.025 0.05 0.075 0.1{
    forvalues size = 1000(1000)10000 {
        mat R = J(500,2,.)

            forvalues x=1(1)500 {
                preserve
                sample `size' , count
                gen temp = runiform()
                gen T=0
                replace T = 1 if temp<0.2
                replace impuestos_pagados = impuestos_pagados * (1+`efecto') if T==1
                reg impuestos_pagados T, robust
                mat R[`x',1]=_b[T]/_se[T]
                restore
            }

    preserve
    clear
    svmat R
    gen reject = 0
    replace reject = 1 if (R1>1.65)
    drop if reject==.
    sum reject
    scalar media = r(mean)

    mat resultados[`i',3] = `efecto'
    mat resultados[`i',2] = media
    mat resultados[`i',1] = `size'
    restore

    local i=`i'+1
    }
}

clear
svmat resultados
rename resultados1 sample_size
rename resultados2 st_power
rename resultados3 efecto
replace st_power=round(st_power,.01)
separate st_power, by(efecto)

twoway (connected st_power1 sample_size) (connected st_power2 sample_size) ///
(connected st_power3 sample_size) (connected st_power4 sample_size) ///
```

```
(connected st_power5 sample_size), ytitle("Power") ///
xtitle("Number of observations") ///
legend(label(1 "1%") label(2 "2.5%") label(3 "5%") label(4 "7.5%") label(5 "10%")) ///
legend(rows(1) title("Effect", size(small)) pos(6) ring(1)) xscale(titlegap(3)) yscale(titlegap(3))
graph export "$output/Figura 3.png", replace

*80% de tratados
clear all
set seed 123
set obs 15000
gen ganancias_estimadas = rnormal(10000,2000)
drop if ganancias_estimadas<0
gen impuestos_pagados = 0.2*ganancias_estimadas + rnormal(0,5000) // cambiamos la varianza del error a 5000
drop if impuestos_pagados<0
gen obs=_n
pctile escuela = obs, nq(10)

local i=1
mat resultados = J(50,4,.)
foreach efecto in 0.01 0.025 0.05 0.075 0.1{
    forvalues size = 1000(1000)10000 {
        mat R = J(500,2,.)

            forvalues x=1(1)500 {
                preserve
                sample ‘size’ , count
                gen temp = runiform()
                gen T=0
                replace T = 1 if temp<0.8
                replace impuestos_pagados = impuestos_pagados * (1+‘efecto’) if T==1
                reg impuestos_pagados T, robust
                mat R[‘x’,1]=_b[T]/_se[T]
                restore
            }

    preserve
    clear
    svmat R
    gen reject = 0
    replace reject = 1 if (R1>1.65)
    drop if reject==.
    sum reject
    scalar media = r(mean)

    mat resultados[‘i’,3] = ‘efecto’
    mat resultados[‘i’,2] = media
    mat resultados[‘i’,1] = ‘size’
    restore

    local i=‘i’+1
    }
}

clear
svmat resultados
rename resultados1 sample_size
rename resultados2 st_power
rename resultados3 efecto
replace st_power=round(st_power,.01)
separate st_power, by(efecto)

twoway (connected st_power1 sample_size) (connected st_power2 sample_size) ///
(connected st_power3 sample_size) (connected st_power4 sample_size) ///
(connected st_power5 sample_size), ytitle("Power") ///
xtitle("Number of observations") ///
legend(label(1 "1%") label(2 "2.5%") label(3 "5%") label(4 "7.5%") label(5 "10%")) ///
legend(rows(1) title("Effect", size(small)) pos(6) ring(1)) xscale(titlegap(3)) yscale(titlegap(3))
graph export "$output/Figura 4.png", replace

*================================================================================*

* 4) Simulacion: control
```

```
clear all
set more off
set seed 123
set obs 15000
gen ganancias_estimadas = rnormal(10000,2000)
drop if ganancias_estimadas<0
gen impuestos_pagados = 0.2*ganancias_estimadas + rnormal(0,500) // cambiamos la varianza del error a 500
drop if impuestos_pagados<0
gen obs=_n
pctile escuela = obs, nq(10)

local i=1
mat resultados = J(50,4,.)
foreach efecto in 0.01 0.025 0.05 0.075 0.1{
    forvalues size = 1000(1000)10000 {
        mat R = J(500,2,.)

            forvalues x=1(1)500 {
                preserve
                sample ‘size’ , count
                gen temp = runiform()
                gen T=0
                replace T = 1 if temp<0.5
                replace impuestos_pagados = impuestos_pagados * (1+‘efecto’) if T==1
                reg impuestos_pagados T ganancias_estimadas, robust
                mat R[‘x’,1]=_b[T]/_se[T]
                restore
            }

    preserve
    clear
    svmat R
    gen reject = 0
    replace reject = 1 if (R1>1.65)
    drop if reject==.
    sum reject
    scalar media = r(mean)

    mat resultados[‘i’,3] = ‘efecto’
    mat resultados[‘i’,2] = media
    mat resultados[‘i’,1] = ‘size’
    restore

    local i=‘i’+1
    }
}

clear
svmat resultados
rename resultados1 sample_size
rename resultados2 st_power
rename resultados3 efecto
replace st_power=round(st_power,.01)
separate st_power, by(efecto)

twoway (connected st_power1 sample_size) (connected st_power2 sample_size) ///
(connected st_power3 sample_size) (connected st_power4 sample_size) ///
(connected st_power5 sample_size), ytitle("Power") ///
xtitle("Number of observations") ///
legend(label(1 "1%") label(2 "2.5%") label(3 "5%") label(4 "7.5%") label(5 "10%")) ///
legend(rows(1) title("Effect", size(small)) pos(6) ring(1)) xscale(titlegap(3)) yscale(titlegap(3))
graph export "$output/Figura 5.png", replace
```